混合言語指示による
多段階ブロック操作ロボット

OmniCampus: shigin123 実行日: 2026年10月29日 (JST)

1. 課題の概要と目的

視覚言語モデル（VLM）に実際の場面画像と日本語・英語・中国語を含む一つの指示を与え、操作の順序を計画させる。分類に続く押し出し、積み重ね、まとめての運搬までを、物理シミュレータ内の接触動作につなぎ、各段階を独立に評価することを目的とした。

使用した指示

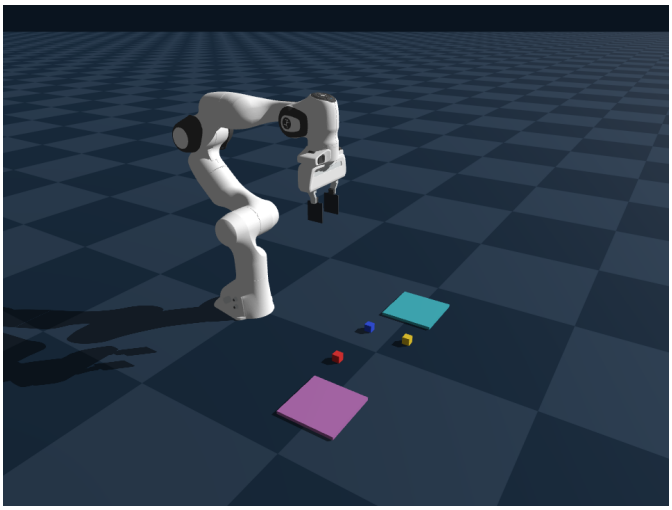
> 青いブロックをトレーAへ、黄色いブロックをトレーBへ移してください。赤いブロックは動かさないでください。
> And then please push the blue block out of the A , and put the yellow block B on the block A.
> 最后把它们一起放到B区域中。一直都不要动红色那个块。

Franka Panda、赤・青・黄のブロック、青緑のトレーAと紫のトレーBを配置した。指示は、①青をA・黄をBへ分類、②青をAの外へ押し出す、③黄を青の上へ積む、④積層を保って2個を一緒にBへ運ぶ、と解釈した。赤は全工程で動かさない。

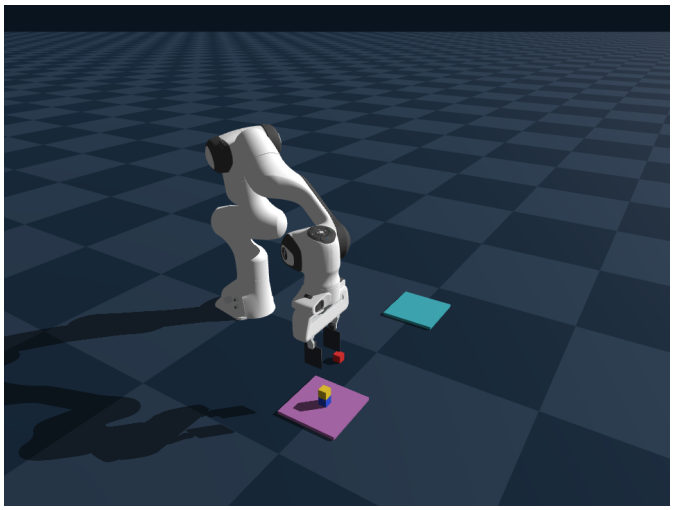
2. AIと制御の接続

実際のカメラ画像 + 混合言語指示 → QwenのJSON行動案 → 対象・操作の検査 → 逆運動学と関節制御 → 位置履歴による成否判定

Qwen3-VL-8B-Instructに操作語彙（pick_place / push_out / stack / move_stack）を提示し、回答計画は与えない。モデルが選んだ対象・支持物・目的地を検査し、赤を動かす操作や赤を支持物にする操作を拒否する。追加学習は行わず推論のみを用いた。



実行前: モデルへ渡した実際の画像



実行後: 同じ試行の最終状態

3. 実行結果と判定方法

提示する正式試行の判定: 条件達成

以下の値は保存された位置履歴から再計算した。モデルのdone出力や動画の見た目だけで成功を判定していない。

段階	位置履歴からの確認	判定
青をAへ	終端の安定窓 0.5 秒を検査	達成
黄をBへ	終端の安定窓 0.5 秒を検査	達成
分類の完了	2対象が各トレー内で安定	達成
青をA外へ押す	上昇 0.1 mm / 水平 176.0 mm	達成
黄を青の上へ	終端の安定窓 0.5 秒を検査	達成
運搬中の積層	389 時点で上下関係を検査	達成
積層したままB内へ	終端の安定窓 0.5 秒を検査	達成

最終位置 (m): 青 [0.5002, -0.2968, 0.0224]、黄 [0.5001, -0.2968, 0.0474]。

赤の最大変位 0.000 mm（許容 10.0 mm）。押し出し中の青の中心上昇は 30 mm以下、終了時はブロック全体がAの外にあることを要求した。

積層条件は水平ずれ 8 mm以下、高さ差 25±6 mm。運搬の開始から終了まで確認し、終端は 0.5 秒以上安定、位置変動上限 5 mm以下を要求した。

時間（仮想 / 実時間）	120.00 / 222.33 秒
VLM工程待ち / 生成時間	82.18 / 6.66 秒
最終積層の水平ずれ / 高さ差	0.08 / 24.95 mm
記録された位置サンプル	1202 点 / 最大許容間隔 0.20 秒

モデルが選んだ操作

1: 青いブロックをAへ移す、2: 黄色いブロックをBへ移す、3: 青いブロックをAの外へ押し出す、4: 黄色いブロックを青いブロックの上に積む、5: 青いブロックを下、黄色いブロックを上に保って、2個を一緒にBへ運ぶ。元のモデル回答、検査後の計画、実行記録の一致を確認した。

この課題設定の正式試行は計 1 回: 条件達成 1、未達成・中止 0、未判定 0。別設定の初期分類課題は合算せず、一般的な成功率の推定とも区別する。

別途、開発・調整時の失敗は 10 回。正式デモ前に、8回の制御校正で把持・積み重ね・搬送を調整した。失敗記録は保持している。 既存UIで新指示を試した際の旧動作スキーマ不一致1件と、資源確認中のプロセス交代による実行前拒否1件は開発記録として別扱いにした。25mm立方体、物理衝突を持つ延長指、緩やかな開閉、位置フィードバック、物理サブステップ4・no-slip反復5を固定後、制御校正が成功した。 その後の正式AI実行は1回で成功した。単一の固定シーンと指示による事例であり、一般的な成功率や多言語汎化を示すものではない。

4. 実行条件と工夫した点

モデル	Qwen3-VL-8B-Instruct / bfloat16
モデルrevision	0c351dd01ed87e9c1b53cbc748cba10e6187ff3b
シミュレータ / Python	Genesis 1.4.4 / Python 3.11.15
推論環境	PyTorch 2.8.0+cu128 / Transformers 5.12.0
物理演算 / GPU	CPU物理演算 / NVIDIA RTX PRO 6000 Blackwell Max-Q Workstation Edition
GPUメモリの計測最大値	描画工程 873 MiB / 推論工程 17,616 MiB（各プロセス）
カメラ / 生成上限	960 × 720 px / max_pixels=65536, max_new_tokens=512
学習 / ソース識別	追加学習なし / manifest SHA-256: 27806a4233f6057cafdc

物理設定: 時間刻み 0.01 秒、サブステップ 4、no-slip反復 5、摩擦円錐 pyramidal、立方体の一辺 25 mm。指当たりの把持力は通常 2 N、2個同時 4 N。手先の高さオフセットは通常 165 mm、2個同時 165 mm。

工夫は、途中で言語が変わる指示を一つの順序付き行動列へ変換し、同じ物体への再操作を許しつつ赤の保護を維持する点にある。モデルの元回答、実行した各操作の開始・終了時刻、連続する位置履歴を対応づけ、初期分類から最終積層までを段階別に再計算した。

押し出しは閉じた指との接触、積み重ねは把持後の解放と重力支持、まとめての運搬は物理衝突を持つ延長指で2物体を同時に把持する方法で実装した。運搬中の上下関係は位置履歴で確認したが、接触力そのものや記録間の瞬間的な動作を、この評価だけで証明するものではない。

延長指は幅×厚さ×長さ 50 × 6 × 60 mm、指当たり追加質量 19.8 g。Pandaに追加した独自の衝突形状であり、標準の指形状とは異なる。元の配布アセットは変更せず派生MJCFを生成する。実機での製作・動作検証は行っていない。

把持は指を徐々に閉じてから力制御へ移し、移動は逆運動学と関節制御を用いる。積み重ね時は物体位置の誤差を回数・移動量に上限のあるフィードバックで補正し、指を徐々に開いて解放する。把持・配置位置にはシミュレータの真値を利用しており、モデルが画素だけから連続動作を直接出力する学習済みVLAではない。

5. 制限と再現方法

検証は固定配置の単純なブロックと、日・英・中が混在する一つの指示例に限られる。各言語や任意指示への一般的な性能を示す実験ではなく、初期分類だけの別課題とも成功率を合算しない。未知物体、視覚遮蔽、配置変更、実機での性能は未検証である。

提出コードには依存関係、タスク設定、実行処理、評価処理を含む。モデル重みと個別の機器設定は含めず、利用者自身が公式配布元からモデルを用意する。共有GPU環境では割り当て確認が必要であり、別ハードウェアでの再現性は未検証である。

提出動画の長さは 70.50 秒（MP4メタデータで確認）。再生速度と省略区間は動画内の表示を参照する。

主な参照元・利用部分

Qwen3-VL-8B-Instruct: 事前学習済みモデルと推論API

Genesis v1.4.4: シミュレーション・IK・公式把持例

Franka ROS: Pandaモデルの上流資料

公式例の制御パラメータ等を参考に、タスク定義、モデル接続、制約検査、記録・評価を追加した。詳しい帰属は提出コードのTHIRD_PARTY_NOTICES.mdを参照。